

# PILL-SO-GOOD · TEAM EXPERIMENT REPORT

## AI13 OBJECT DETECTION PROJECT

경구약제 이미지 객체 검출

팀 최종 보고서

데이터 커버리지 확장에서 2-Stage 다중 분류기 앙상블까지

| 팀명    | Pill-So-Good          |
|-------|-----------------------|
| 프로젝트  | [AI13] 경구약제 이미지 객체 검출 |
| 평가지표  | mAP@[0.75:0.95]       |
| 최종 결과 | Leaderboard 0.64178   |

## 요약

본 프로젝트는 한 이미지에 존재하는 여러 경구약제의 위치와 종류를 동시에 예측하는 객체 검출 문제다. 평가지표가 mAP@[0.75:0.95]이므로 분류 정답뿐 아니라 bbox가 실제 객체와 매우 정밀하게 겹쳐야 한다. 팀은 각자 end-to-end 파이프라인을 독립적으로 검증하되, 결과는 개인별 작업 목록이 아니라 공통 가설을 검증한 하나의 실험 축으로 통합하였다.

초기 Kaggle 56종 데이터에서는 내부 성능과 리더보드 사이에 큰 차이가 발생했다. 이를 모델 크기 부족으로 단정하지 않고 라벨 누락, 클래스 매핑, 장면 누수, 미학습 클래스와 촬영 도메인 차이를 차례로 점검했다. 이후 AIHub 데이터를 56종 보강과 118종 합집합으로 단계적으로 확장하고, YOLO 계열, Faster R-CNN, RT-DETR, ConvNeXt-ResNet 분류기, NMS-TTA-WBF, 정식 2-Stage를 비교했다. 팀 전체로 총 83회의 제출 실험을 수행했으며, 실패 횟수는 불완전한 팀 집계를 제시하는 대신 실험 로그로 확인 가능한 주요 실패·전환 사례만 정리했다.

[최종 결론] 가장 큰 개선은 모델 대형화가 아니라 클래스 커버리지와 장면 다양성 확대에서 발생했다. 최종 채택안은 v4 데이터로 재학습한 1-class YOLO11s가 위치를 찾고, ResNet18 분류기 10개가 각 Crop의 118종 확률을 평균하는 2-Stage 구조다. 10개 중 9개는 기존 학습 모델이며, 나머지 1개는 pseudo-label 데이터 817개를 추가해 학습한 ResNet18이다. 최종 리더보드 점수는 0.64178이다.

|                    |                   |                   |              |                           |
|--------------------|-------------------|-------------------|--------------|---------------------------|
| 0.64178<br>최종 리더보드 | 118종<br>최종 클래스 범위 | 83회<br>팀 전체 제출 실험 | 15개<br>학습 모델 | ResNet18 10개<br>최종 확률 앙상블 |
|--------------------|-------------------|-------------------|--------------|---------------------------|

## 1. 문제 정의와 평가 전략

### 1.1 문제와 제출 조건

각 예측 행은 image\_id, category\_id, bbox\_x, bbox\_y, bbox\_w, bbox\_h, score를 포함한다. annotation\_id는 행마다 고유해야 한다. 학습 시에는 원본 category\_id를 0부터 시작하는 연속 YOLO class index로 변환해 사용하고, 제출 시에는 저장한 class index→category\_id 매핑으로 다시 복원한다. 이 역매핑이 어긋나면 모델이 올바르게 예측해도 제출에서는 다른 약으로 평가된다.

### 1.2 왜 높은 IoU가 중요한가

대회 점수는 IoU 0.75-0.80-0.85-0.90-0.95의 AP를 평균한다. 따라서 객체를 대략 찾는 능력보다 경계를 정확히 맞추는 능력이 중요하다. 100×100픽셀 상자가 가로와 세로 방향으로 각각 5픽셀 이동하면 IoU가 약 0.82로 떨어져 AP0.85 이상 구간을 잃을 수 있다.

### 1.3 초기 가설과 수정

초기에는 더 큰 검출기와 더 긴 학습이 성능을 높일 것이라 보았다. 그러나 Kaggle 중심 YOLO의 첫 제출이 약 0.39인 반면 내부 검증은 매우 높았다. 이 차이는 단순 과적합뿐 아니라 Train/Test 클래스 범위, 장면 유사도, 라벨 정합성, 촬영 환경 차이가 함께 만든 문제로 판단했다. 이후에는 모델 크기 확대보다 데이터

커버리지·장면 다양성·검증 분할을 우선 점검하고, 검출과 분류를 분리해 병목을 따로 검증하는 방향으로 실험을 전환했다.

## 2. 데이터 감사와 전처리

### 2.1 JSON을 이미지·객체 단위로 재구성

Train 이미지는 약 232장이지만 JSON은 763개로 여러 하위 폴더에 분산되어 있었다. JSON 한 개를 이미지 한 장으로 취급하면 다중 객체 중 일부만 남길 수 있으므로 모든 JSON을 재귀 탐색한 뒤 file\_name 기준으로 객체를 다시 묶었다. bbox 키가 없거나 비어 있거나 길이가 4가 아닌 항목은 제외하고, 유효한 객체만 annotation\_id를 부여했다.

- 이미지와 JSON stem·크기·약품 코드·객체 수 일치 여부 검사
- bbox의 음수, 0 이하 폭·높이, 이미지 범위 초과, 중복 좌표 검사
- 손상 이미지와 불완전 장면은 hard drop하고 제외 이유를 audit CSV에 기록
- 동일 해시가 서로 다른 클래스에 연결된 충돌 Crop 22개 제거

**핵심 트러블슈팅** 초기 전처리에서 다중 알약 이미지의 첫 객체만 라벨로 남아 나머지가 배경으로 학습되는 문제가 있었다. 모든 annotation과 bbox를 순회하도록 수정한 뒤 객체 누락 무결성 검사를 통과시켰다.

### 2.2 클래스 매핑과 데이터 누수 방지

전처리에서는 Kaggle JSON의 dl\_idx를 원본 category\_id로 읽고, 정렬된 category\_id 목록으로 0부터 시작하는 YOLO class index와 양방향 매핑표를 생성했다. AIHub와 Kaggle을 통합할 때는 두 데이터에 공통으로 존재하는 dl\_mapping\_code를 약품 연결 기준으로 사용하고, 코드의 숫자부가 Kaggle category\_id와 일치하는지도 확인했다. 학습 라벨에는 연속 class index를 사용하고 제출 시에는 저장된 역매핑으로 category\_id를 복원했다. 또한 같은 약 조합을 각도만 바꾼 장면이 Train과 Validation에 동시에 들어가지 않도록 조합 단위 Group Split을 적용했다. 엄격한 Kaggle audit에서는 232장 중 223장이 유효했고, 176장/47장으로 분할했으며 group overlap은 0이었다. 다만 Validation에는 56종 중 29종만 포함되어 local score의 대표성이 제한됨을 함께 기록했다.

## 2.3 단계적 데이터 확장

| 데이터 버전              | 규모                                                            | 목적                  | 관찰                          |
|---------------------|---------------------------------------------------------------|---------------------|-----------------------------|
| Kaggle 기준           | 원본 232장 · audit<br>유효 223장 · 56종                              | 파이프라인·제출 검증         | 리더보드 약 0.39, 클래스 범위 한계      |
| Kaggle+AIHub<br>56종 | AIHub 매칭 54종 +<br>Kaggle 전용 2종                                | 동일 클래스의 표본 보강       | 내부 mAP50-95 0.91745→0.95326 |
| Union118 중간         | AIHub 116종 +<br>Kaggle 보완 2종 ·<br>Train 8,443장                | Test 미학습 클래스 대응     | YOLO 제출 0.60749             |
| v3                  | AIHub+Kaggle 통합<br>118종 · 8,898장 ·<br>34,314 bbox             | 118종 커버리지 확보        | 약한 클래스와 장면 부족 확인            |
| v4                  | v3 기반 취약<br>클래스·장면 보강 ·<br>11,713장 · 44,818<br>bbox · 4,062조합 | 취약 클래스·장면 다양성<br>보강 | 100개 미만 클래스 23종→6종          |

본 보고서의 v3와 v4는 YOLO 모델 버전이 아니라 팀이 전처리·정제·보강하며 구축한 학습 데이터셋의 버전을 의미한다. v3는 AIHub와 Kaggle을 통합한 118종, 8,898장, 34,314개 bbox로 구성됐지만 클래스별 표본 수와 촬영 장면이 불균형했다. v4에서는 표본이 부족한 클래스와 촬영 각도·배경·장면을 집중적으로 보강해 11,713장, 44,818개 bbox, 4,062개 약품 조합으로 확장했다. 그 결과 객체 수가 100개 미만인 클래스가 23종에서 6종으로 감소했다. 최종 모델에서는 ResNet18 분류기뿐 아니라 1-class YOLO11s 검출기도 이 v4 데이터셋으로 재학습했다.

AIHub 116종에 존재하지 않는 K-003351과 K-003483은 Kaggle 데이터로 보완해 118종을 완성했다. 다운로드 전에는 용량이 작은 라벨 압축을 먼저 확인해 필요한 코드가 실제 존재하는지 검토했다. Test와 매우 유사한 장면의 혼입 가능성을 점검하기 위해 이미지를 64×64 grayscale로 정규화하고 cosine similarity 0.95 초과 항목을 근접 중복 후보로 탐색했다. 이 방식은 배경 유사도에 민감할 수 있으므로 후보를 장면 단위로 확인한 뒤 AIHub 이미지 211장·연결 쌍 257개를 제외했다. 조합 단위 분할에서는 4,062개 조합을 유사 장면 기준 2,895개 group으로 묶었고, 연결된 조합 1,167개가 Train과 Validation에 갈라지지 않도록 했다.

## 2.4 클래스 불균형과 합성 데이터

v3 기준 클래스별 Crop은 최소 18개, 최대 741개로 편중되었고 100개 미만 클래스가 23종이었다. 예를 들어 K-005000은 7개 조합·21개 Crop뿐이었지만 전체 중앙값은 약 67개 조합·197개 Crop이었다. Weighted sampler는 희소 이미지를 반복해 빈도는 맞출 수 있어도 새로운 각도·배경을 만들지는 못하므로, 단순 균형화와 장면 다양성을 구분해 해석했다. 부족한 클래스는 GrabCut으로 알약을 분리해 새 배경에

3~6개씩 배치하는 Copy-Paste 합성도 검토했다. 객체 크기 60~80%, 객체 간 여백 25px, 위치 재시도 최대 100회를 사용해 겹침을 줄였다.

그러나 외부 데이터의 양만 늘린다고 항상 Test 점수가 오르는 않았다. 클래스 수, 장면 다양성, 라벨 완전성, 학습·추론 조건 일치가 동시에 충족되어야 효과가 있었다.

### 3. 모델 탐색: 한 번에 풀 것인가, 역할을 나눌 것인가

#### 3.1 경량 YOLO 기준선

YOLO11n은 작은 데이터에서 전체 파이프라인이 정상 동작하는지 빠르게 확인하기 위한 baseline으로 사용했다. 이후 YOLO11s를 주력으로 선택했다. 사전학습 가중치, 빠른 학습·추론, 일관된 검증 도구, T4 GPU에서의 비용 대비 성능이 선택 이유였다. YOLO11m과 1280 fine-tuning도 비교했지만 더 큰 모델과 해상도가 일관된 향상으로 이어지지 않았고, 일부 실험에서는 과적합과 추론 비용만 증가했다.

#### 3.2 Faster R-CNN + ResNet50

속도보다 bbox와 클래스 정확도를 우선하는 대안으로 Faster R-CNN을 실험했다. 약 34 epoch 학습에 약 1,000분이 소요됐고, 내부 지표는 높았지만 리더보드 점수는 약 0.58에 머물렀다. 중복 검출, 클래스 오분류, K-005000 미검출이 남았으며, 높은 정확도의 2-stage detector라도 데이터 커버리지와 annotation 품질 문제를 자동으로 해결하지는 못했다.

#### 3.3 RT-DETR-L

YOLO와 다른 Transformer 기반 오류 패턴을 얻기 위해 RT-DETR-L 960을 학습했다. 초기에 conf=0.001로 8,500개의 저신뢰도 검출 후보가 남아 배경 Crop이 대량 생성되었지만, conf=0.3과 실험적 cross-class NMS IoU=0.5를 후처리로 적용해 317개로 줄이면서 내부 mAP75-95 0.98486을 유지했다. 단독 제출 0.61444로 Union118 YOLO 0.60749보다 높아 구조적 다양성의 가치를 확인했다.

#### 3.4 분류기 결합

알약은 색·형태보다 작은 각인과 표면 패턴이 클래스 구분에 결정적이므로 검출 bbox를 Crop해 별도 분류기로 다시 판별했다. ConvNeXt118은 Validation macro F1 0.99756을 기록했지만 118-class YOLO의 라벨을 단순 교체하는 방식은 end-to-end mAP를 개선하지 못했다. 두 모델이 같은 어려운 클래스에서 함께 틀리고 YOLO의 클래스 정보가 이미 강했기 때문이다.

ResNet50은 384×384 입력, head→layer4의 2단계 fine-tuning, 3-way TTA를 통해 세부 특징을 보존하도록 설계했다. 다만 최종 앙상블에서는 ResNet18이 ResNet50·EfficientNet-B0와 거의 같은 판단을 내면서 더 가볍고, 서로 다른 학습 레시피를 여러 개 운영하기 유리했다.

## 4. 후처리와 앙상블 실험

### 4.1 Confidence-NMS-TTA

낮은 confidence는 Recall을 높이지만 중복·배경 예측을 증가시킨다. class-aware/cross-class NMS, IoU, max\_det, TTA를 비교한 결과 YOLO는 학습 해상도와 동일한 standard 설정이 가장 안정적이었다. 416으로 학습한 최종 검출기를 640과 960으로 추론했을 때 동일한 내부 평가 기준의 competition mAP75-95가 각각 약 0.05와 0.33 하락했다. 해상도 불일치가 모델 대형화보다 큰 손실을 만들 수 있음을 확인했다.

### 4.2 YOLO-RT-DETR WBF

Weighted Boxes Fusion은 겹치는 박스를 버리지 않고 모델 신뢰도에 따라 좌표를 평균한다. 내부 검증에서 YOLO 0.9 + RT-DETR 0.1, WBF IoU 0.7이 0.99469로 YOLO 단독 0.99464보다 0.00005 높았지만, 리더보드는 0.61209로 RT-DETR 단독 0.61444보다 낮았다. 최종 채택 경로에서도 cross-detector WBF 적용 후 고IoU 점수가 약 0.0081 하락했다. 이미 정밀한 YOLO 상자에 다른 검출기의 좌표를 평균하면서 경계가 이동한 결과로 해석했으며, 내부 Validation의 극소 개선이 Test 일반화나 고IoU 정확도를 보장하지 않는 사례로 기록했다.

### 4.3 오류 시각화로 확인한 공통 오분류

이미지 979-980의 흰색 원형 알약은 팀 검토 기준 category 5000으로 판단했지만, 실험한 모델들은 반복적으로 category 22074로 분류했다. 두 약이 색상과 외형이 매우 유사하고 각인 정보가 흐려지면 같은 특징 공간에 모이기 때문이다. 특정 Test 이미지의 라벨을 사람이 직접 바꾸는 방식은 평가 공정성 논란이 있을 수 있어 최종 제출에는 수동 교정을 적용하지 않았다. 대신 이 사례를 데이터 커버리지와 유사 클래스 분리 능력의 한계로 기록했다.




그림 1. category 22074로 예측된 흰색 원형 알약 모음. 이미지 979-980은 팀 검토상 category 5000이지만 여러 모델이 공통 오분류했다.

한편  $\text{conf}=0.001$ 에서 나타난 배경 Crop은 좌표 함수 오류가 아니라 저신뢰도 검출이 분류기로 전달된 문제였다. 시각화 단계에서  $\text{conf}=0.10$ 을 적용하자 979-980에서는 실제 알약 6개만 남아, Crop 함수와 detector threshold 문제를 분리해 진단할 수 있었다.

#### 4.4 로그로 확인된 주요 실패와 방향 전환

팀 전체 실패 횟수는 로그 범위가 서로 달라 합계로 단정하지 않았다. 아래에는 결과 수치와 원인이 확인된 대표 사례만 남겼다. 실패를 삭제하지 않고 다음 실험의 가설로 연결한 것이 데이터 확장과 정식 2-Stage 전환의 근거가 됐다.

| 시도                          | 관찰 결과                                    | 다음 판단                                          |
|-----------------------------|------------------------------------------|------------------------------------------------|
| YOLO11s 1280 fine-tuning    | 내부 0.92743 < 960 모델 0.95214              | 해상도 확대가 항상 성능을 높이지 않음                          |
| AIHub 56종 ConvNeXt Hybrid   | 최고 0.90458 < 기존 Hybrid 0.96446           | 표본 수보다 Train/Test 도메인 정합성이 중요                  |
| Union118 YOLO               | local 0.99464, leaderboard 0.60749       | Validation이 실제 Test 분포를 대표하지 못함                |
| RT-DETR $\text{conf}=0.001$ | 8,500개 저신뢰도 검출 후보와 다수 배경 Crop            | $\text{conf}=0.3$ + cross-class NMS로 317개까지 정리 |
| YOLO-RT WBF                 | local 0.99469, leaderboard 0.61209       | 미세한 local 향상은 일반화 근거가 아님                       |
| YOLO 118-class + ConvNeXt   | 분류기 교체가 local mAP를 높이지 못함                | 역할이 겹쳐 1-class detector로 재설계                   |
| 정식 2-Stage                  | local 0.99351 < YOLO 0.99464, LB 0.62204 | local 순위보다 외부 일반화와 오류 구조를 함께 평가                |
| 979-980 수동 라벨 검토            | 5000을 22074로 공통 오분류                      | 수동 수정은 제출에 미적용, 개선 과제로만 기록                     |

## 5. 정식 2-Stage로의 전환

### 5.1 역할을 완전히 분리한 이유

기존 YOLO+분류기 방식은 추론 단계가 둘이어도 YOLO가 118종 분류를 동시에 수행해 역할이 중복됐다. 이를 검증하기 위해 원본 라벨을 손상하지 않고 별도 복사본의 class label만 pill=0으로 바꿔 1-class detector를 학습했다. Detector는 위치와 Recall에만 집중하고, classifier는 Crop의 색상·형태·각인만 판별하도록 했다.

최종 채택 구조: 검출과 세부 분류의 역할 분리 + 다양성 기반 확률 앙상블



그림 2. 최종 채택된 역할 분리형 2-Stage 구조

### 5.2 ConvNeXt 2-Stage와 ResNet50 2-Stage

1-class YOLO11s 960→ConvNeXt118 구조는 detector weight 0.75, classifier weight 0.25에서 내부 competition mAP75-95 0.99351, 리더보드 0.62204를 기록했다. 또 다른 경로에서는 YOLO11s→ResNet50, 384×384 Crop, 3-way TTA, unknown threshold를 적용해 미세 각인과 미학습 객체 대응을 실험했다. 두 결과 모두 ‘찾기’와 ‘구분하기’를 분리하는 방향이 Test 도메인 변화에 더 견고할 수 있음을 보여줬다.

### 5.3 1차 최종 ResNet18 9개 확률 앙상블

단일 분류기 성능이 정체된 뒤에는 동일한 상자에 대해 서로 다르게 틀리는 모델을 모았다. 최종 detector는 YOLO11s 단일 클래스, imgsz=416, conf=0.01로 공통 상자를 만들고 bbox에 10% 여백을 더했다. v3/v4 데이터, 224/384 Crop, 약한/강한 증강, 밝기 정규화, CLAHE, 10-20-30-40 epoch checkpoint를 조합한 ResNet18 9개의 softmax 확률을 산술평균했다. 최종 score는 detector confidence와 평균 class probability의 곱으로 계산했다. 검출기는 한 번만 실행하고 모든 분류기가 같은 Crop을 보므로 박스 대응 문제 없이 분류 다양성만 활용할 수 있다.

| 구성        | 단독 또는 조합 점수 | 판단                  |
|-----------|-------------|---------------------|
| 단일 최고 분류기 | 0.62464     | 384 Crop + 강한 증강    |
| 성적 좋은 3개  | 0.61925     | 서로 비슷하게 틀려 조합 효과 부족 |
| 분류기 6개    | 0.62632     | 단일 모델보다 개선          |
| 분류기 9개    | 0.63420     | 1차 최종안              |

| 구성                   | 단독 또는 조합 점수 | 판단             |
|----------------------|-------------|----------------|
| 분류기 11개              | 0.63392     | 추가 모델이 노이즈를 더함 |
| 9개 + ResNet50        | 0.63345     | 판단 다양성 부족      |
| 9개 + EfficientNet-B0 | 0.63001     | 기존 오류와 높은 상관   |

**왜 단독 성적이 낮은 CLAHE 모델도 포함했는가** CLAHE 모델의 단독 점수는 0.61604였지만 제외하면 최종 점수가 하락했다. 앙상블에서 중요한 것은 각 모델의 단독 순위가 아니라 오류 상관성이 낮아 다른 모델의 실수를 보완하는가였다.

## 5.4 1차 최종 모델의 강점과 선정 이유

1차 최종 모델은 단일 모델의 내부 최고점이 아니라 외부 평가 성능, 오류 다양성, 추론 비용, 재현성을 함께 고려해 선정했다. 1-class YOLO11s와 ResNet18 9개 확률 앙상블은 위치 검출과 세부 분류를 분리해 당시 리더보드 0.63420을 기록했다.

- **역할 분리:** Detector는 위치와 Recall에 집중하고 classifier는 색상·형태·각인을 판별하므로 오류 원인을 단계별로 진단하고 개선하기 쉽다.
- **정확도와 일반화:** 118-class YOLO 단독이나 ConvNeXt 결합보다 외부 평가 성능이 높았고, 서로 다른 데이터·해상도·증강으로 학습한 분류기들이 공통 오류를 줄였다.
- **효율성과 재현성:** YOLO11s와 ResNet18은 ResNet50·대형 검출기보다 가벼워 T4 환경에서도 운영하기 쉽고, detector 결과와 분류 확률을 캐시해 앙상블을 빠르게 재평가할 수 있다.
- **앙상블 규모의 균형:** 9개 모델은 6개보다 성능이 높고 11개보다 노이즈가 적었다. 단독 성적보다 오류 상관성이 낮은 구성을 우선한 것이 최종 성능 향상으로 이어졌다.

## 5.5 v4 검출기 재학습과 pseudo-label로 0.64178 달성

0.63420 이후 파이프라인을 재점검한 결과, 분류기는 11,713장의 v4 데이터로 갱신했지만 모든 분류기가 공유하는 1-class detector는 8,898장의 v3 데이터로 학습된 상태였다. 동일한 YOLO11s-imgsz 416-60 epoch 조건에서 detector도 v4로 재학습하자 모든 Crop의 품질이 함께 개선되며 약 +0.0057의 상승을 얻었다.

| 검출기 | 학습 데이터       | Precision | Recall | mAP50-95 | Test 상자 |
|-----|--------------|-----------|--------|----------|---------|
| 이전  | v3 · 8,898장  | 0.9941    | 0.9936 | 0.9852   | 3,433개  |
| 최종  | v4 · 11,713장 | 0.9958    | 0.9958 | 0.9869   | 3,229개  |

예측 상자는 204개 감소했지만 내부 정답 대조 결과 감소분의 대부분은 낮은 점수의 헛검출이었다. 분류기 하나의 개선은 평균 확률에 1/10만 반영되지만 detector 개선은 10개 분류기가 받는 모든 Crop을 바꾸므로 파급력이 더 컸다.

두 번째 개선은 정답이 없는 Test 이미지에서 고신뢰도 예측만 선별해 ResNet18을 추가 학습한 것이다. 3,229개 상자 중 학습 데이터와의 유사도가 하위 30%인 낯선 장면, 기존 ResNet18 분류기 9개의 top-1 만장일치, k-NN 예측과 앙상블 top-1의 일치, 평균 확률 0.90 이상을 모두 만족한 817개만 pseudo-label 데이터로 사용했다. 외부 정답은 사용하지 않고 Test 이미지와 모델 예측만 활용한 transductive-semi-supervised learning이며, 적용 전 대회 규정 허용 범위를 확인했다. 이 pseudo-label ResNet18의 단독 점수는 0.62634로, 동일 조건에서 pseudo-label을 사용하지 않은 모델의 0.62070보다 높았다.

| 개선 단계                    | Leaderboard | 개선 폭    | 의미                          |
|--------------------------|-------------|---------|-----------------------------|
| v3 detector + 분류기 9개     | 0.63420     | -       | 1차 최종안                      |
| v4 detector 재학습          | 0.6399      | +0.0057 | 헛검출 감소·모든 Crop 개선           |
| pseudo-label ResNet18 추가 | 0.64178     | +0.0019 | Test 촬영 장면을 학습한 ResNet18 추가 |

순서가 중요했다. Pseudo-label 데이터로 학습한 ResNet18은 이전 detector에서는 앙상블 결과를 바꾸지 못했지만, v4 detector가 헛검출을 줄인 뒤에는 +0.0019를 기여했다. 새 detector의 3,229개 상자에서는 최종 ResNet18 앙상블 10개를 포함한 구조·전처리가 다른 12개 후보 분류 모델의 top-1 클래스가 100% 일치했다. 다만 모델별 확률 분포가 달라 최종 confidence 순위는 변할 수 있었고, pseudo-label ResNet18은 이 순위를 보정해 AP 개선에 기여했다. 이후 개선의 중심은 추가 classifier보다 bbox 품질로 전환했다.

## 6. 실험 결과와 선택 근거

### 6.1 주요 리더보드 결과

| 실험                                       | Leaderboard | 다음 판단                    |
|------------------------------------------|-------------|--------------------------|
| 초기 Kaggle 중심 YOLO                        | 약 0.39      | 모델보다 데이터·검증 구조부터 재점검     |
| Faster R-CNN + ResNet50                  | 약 0.58      | 높은 비용에도 커버리지·중복 검출 문제 지속 |
| 중간 2-Stage YOLO→ResNet50                 | 약 0.60      | 역할 분리 가능성 확인, 데이터·OOD 보강 |
| Union118 YOLO11s                         | 0.60749     | 118종 클래스 확장이 실제 병목을 완화   |
| RT-DETR-L                                | 0.61444     | 대안 구조의 상보성 확인            |
| YOLO 0.9 + RT 0.1 WBF                    | 0.61209     | 내부 최적화가 외부 점수로 이어지지 않음   |
| 1-class YOLO→ConvNeXt118                 | 0.62204     | 완전한 역할 분리의 효과            |
| YOLO→ResNet18 9-model ensemble           | 0.63420     | 1차 최종안                   |
| v4 detector + ResNet18 10-model ensemble | 0.64178     | 최종 채택                    |

팀 실험 경로의 주요 외부 평가 결과




그림 3. 팀이 검증한 주요 제출 방식의 외부 평가 결과

## 6.2 정성적 검출 결과

정량 지표만으로는 중복 검출, 작은 각인, 흰색 원형 약의 혼동을 설명하기 어렵다. 아래에는 최종 모델의 대표 성공 사례와 모델별 비교 결과를 제시했다. 동일한 이미지에 정답·예측 bbox, category\_id, confidence를 함께 표시해 오류 유형을 비교했다.




그림 4. 최종 모델의 대표 검출 결과

## 6.3 최종 점수의 여정




그림 5. 데이터 커버리지와 분류기 다양성 확장에 따른 최종 모델 점수

0.42532에서 0.64178까지 총 0.21646을 개선했다. 가장 큰 단일 상승은 56종에서 93종으로 클래스 커버리지를 넓힌 단계(+0.14406)였다. 이후 118종 확장과 ResNet18 9개 확률 앙상블로 0.63420에 도달했고, detector를 v4 데이터로 재학습한 뒤 pseudo-label 데이터로 학습한 ResNet18 1개를 추가해 최종 10개 앙상블과 리더보드 0.64178을 달성했다. 모든 분류기가 공유하는 bbox 품질과 Test 촬영 장면의 다양성이 마지막 개선을 만들었다.

## 6.4 정답 치환(Oracle)로 병목 분해

검출과 분류 중 어느 단계가 더 큰 병목인지 확인하기 위해 동일한 Oracle 내부 검증 세트에서 한 요소씩 정답으로 바꿔 평가했다. 실제 파이프라인은 내부 mAP 0.9780, 정답 bbox만 적용하면 0.9933(+0.0153), 정답 class만 적용하면 0.9835(+0.0055), 두 요소를 모두 정답으로 바꾸면 1.0000이었다. 내부 기준에서는 bbox 개선 여지가 분류보다 컸고, 1.0000 결과로 평가 구현도 검증했다. 이 수치는 검출기 단독 성능표와 평가 대상·파이프라인이 달라 직접 비교하지 않았다.




그림 6. 정답 bbox-class 치환으로 분해한 내부 성능 병목

Top-5 후보 확장은 +0.0001에 그쳤고 이미 118종 전체가 후보에 등장했다. 즉 남은 문제는 정답 클래스의 단순 후보 누락보다 유사 약품 사이의 순위와 데이터 표현 문제에 가까웠다. 모델 예측에서 추정된 Test

클래스 분포를 기반으로 계산한 초기 휴리스틱 상한은 당시 0.63420과 유사했지만, 이는 실제 Test 정답으로 계산한 이론적 상한이 아니다. v4 detector와 pseudo-label 개선으로 0.64178을 달성한 뒤에도 병목의 중심이 bbox 품질과 Test 도메인 커버리지라는 해석은 유지됐다.

## 6.5 내부 Validation과 리더보드의 불일치

Union118 YOLO는 Kaggle val mAP50-95 0.99092, competition mAP75-95 0.99464를 기록했지만 리더보드는 0.60749였다. 반대로 내부 점수가 조금 낮은 2-Stage가 외부 평가에서 더 높았다. Group Split으로 동일 조합의 직접 중복은 제거했지만, Train과 Validation이 동일한 AIHub 촬영 장비·배경·각도 패턴을 공유했고 Validation의 클래스 범위도 전체 Test 분포를 대표하지 못했기 때문이다. 따라서 최종 모델은 local 최고점 하나가 아니라 외부 점수, 오류 시각화, 클래스 커버리지, 재현성을 함께 고려해 선정했다.

## 7. 트러블슈팅

| 문제               | 원인 진단                        | 해결 및 교훈                               |
|------------------|------------------------------|---------------------------------------|
| 다중 객체 누락         | 첫 annotation만 추출             | 모든 bbox 순회 + 객체 수 무결성 검사              |
| 손상 JSON·비정상 bbox | 키 누락·빈 값·범위 초과               | hard drop, audit CSV, 시각화 샘플링         |
| 클래스 오매핑          | YOLO index와 category_id 혼용   | 단일 매핑표를 Source of Truth로 고정           |
| local/Test 격차    | 조합 누수·Validation coverage 부족 | Group Split, 누수 이미지 제거, 외부 제출로 교차검증   |
| RT-DETR 배경 Crop  | conf=0.001에서 query 대량 잔존     | conf=0.3, cross-class NMS 0.5         |
| 2-Stage 배경 Crop  | 검출기의 저신뢰도 FP 전달              | 점검 conf=0.10, Crop 함수와 detector 문제 분리 |
| 흰색 약 오분류         | 유사 외형·희소 장면·흐린 각인            | 979·980 수동 교정은 미적용, 추가 데이터 과제로 기록     |
| ResNet F2 정체     | BatchNorm 통계 변동              | 일부 layer freeze, head 재초기화, AdamW→SGD |
| Colab 재시작        | 경로 변수·패키지·메모리 초기화            | 경로 복구 셀, checkpoint, 단계별 캐시           |
| GPU OOM·batch=-1 | 자동 batch와 대량 추론              | 양의 batch 명시, stream 추론, 캐시 해제         |

**공통 교훈** 오류를 ‘모델이 못했다’로 묵지 않고 데이터, 매핑, 검출, Crop, 분류, 후처리, 실행 환경으로 분해하자 해결 방향이 명확해졌다. 특히 시각화는 bbox 좌표 오류와 저신뢰도 배경 오검출을 구분하는데 결정적이었다.

로그로 확인된 실패 중 배경 제거, CLAHE, 640 추론, 960 추론은 서로 다른 시도처럼 보이지만 공통 원인은 학습과 추론 조건의 불일치였다. 이 패턴을 확인한 뒤부터는 한 번에 한 요소만 바꾸고, 입력 해상도·Crop·색상 처리·mask 생성 방식을 학습과 추론에서 동일하게 고정했다.

## 8. 최종 파이프라인과 재현성

1. AIHub-Kaggle 라벨을 통합하고 품질·누수·그룹 분할 검사를 수행한다.
2. v4 데이터로 재학습한 YOLO11s를 pill 단일 클래스로 사용해 객체 위치만 검출한다.
3. 검출 bbox에 10% 여백을 주어 알약 Crop을 생성한다.
4. 기존 ResNet18 9개와 pseudo-label 데이터 817개로 추가 학습한 ResNet18 1개가 각 Crop의 118종 확률을 출력한다.
5. 10개 확률을 평균하고 detector confidence와 결합해 category와 score를 결정한다.
6. 제출 전 image 누락, annotation\_id, category 매핑, bbox 범위, score 범위를 검사한다.

장시간 학습은 model weight뿐 아니라 optimizer와 scheduler 상태를 함께 checkpoint로 저장해야 실제 중단 지점에서 재개할 수 있다. detector 결과와 분류 확률 행렬도 별도 캐시해 앙상블 조합을 수초 내 재평가하도록 구성했다. 최종 노트북은 학습 플래그를 끈 상태에서 섹션 5부터 실행하며, 저장된 가중치로 약 8분 안에 submission을 재생성할 수 있다. 0.64178 제출본과 상자·라벨 일치 검증을 완료했다.

## 9. 결론과 한계

팀의 실험은 단일 모델 경쟁이 아니라 하나의 문제를 여러 가설로 분해한 과정이었다. YOLO, Faster R-CNN, RT-DETR, ConvNeXt와 ResNet 계열, WBF와 TTA를 비교한 뒤 1-class detector와 ResNet18 9개 앙상블로 0.63420을 달성했다. 이후 분류기는 v4로 갱신됐지만 detector는 v3에 머물러 있던 불일치를 발견해 detector를 v4로 재학습했고, pseudo-label 데이터 817개로 학습한 ResNet18 1개를 기존 9개에 추가해 최종 10개 앙상블과 리더보드 0.64178을 달성했다. 새 detector에서 최종 앙상블을 포함한 12개 후보 분류 모델의 top-1 클래스가 모두 일치했지만 확률 분포는 달랐다. 이를 통해 추가 ResNet18의 역할은 클래스 자체를 바꾸기보다 confidence 순위를 보정하는 데 있었고, 남은 핵심 개선 과제는 bbox 품질이라고 판단했다.

### 9.1 핵심 인사이트

- 가장 큰 성능 레버는 모델 크기가 아니라 Test에 등장할 클래스와 장면의 커버리지였다.
- Fine-grained pill recognition에서는 검출과 분류를 분리하면 각 단계의 오류를 독립적으로 진단할 수 있다.
- 앙상블은 성적이 좋은 모델만 모으는 작업이 아니라 서로 다르게 틀리는 모델을 찾는 작업이다.
- 내부 검증이 거의 1.0이어도 동일 촬영 환경과 클래스 누락 때문에 실제 Test 성능을 과대평가할 수 있다.
- 모든 분류기가 공유하는 detector 개선은 각 classifier를 개별 개선하는 것보다 파급력이 크다.
- Pseudo-label 데이터로 학습한 ResNet18은 예측 라벨 자체보다 기존 Train에 없던 Test 촬영 장면을 학습하는 데 가치가 있었다.

### 9.2 한계와 후속 과제

- 별도 촬영 환경과 모든 118종을 포함한 holdout을 구축해 local/Test 순위 불일치를 줄인다.
- K-005000-K-022074처럼 유사한 흰색 원형 약의 앞·뒷면과 각도별 장면을 추가 수집한다.
- 특징 공간 거리와 앙상블 불일치를 이용해 '식별 불가'를 출력하는 OOD calibration을 별도 검증한다.

- 고IoU 구간을 위해 bbox annotation 재검수와 class-agnostic box refinement를 실행한다.
- Test 입력의 밝기·배경·촬영 거리 분포를 Train과 직접 비교해 도메인 차이를 수치화한다.
- 모든 118종과 새로운 조합·촬영 조건을 포함한 신뢰 가능한 holdout을 먼저 만든 뒤 weighted ensemble을 재검증한다.

### 9.3 서비스 적용 시사점

현재 모델은 학습된 촬영 환경에서 알약 위치를 높은 Recall로 찾지만, 미학습 약도 아는 약 중 하나로 자신 있게 분류할 수 있다. 의료 도메인에서는 틀린 확신이 위험하므로 자동 판독보다 상위 후보 제시와 사용자 확인 방식이 적절하다. 장기적으로는 모델 교체보다 약품 데이터베이스의 지속적인 커버리지 갱신과 OOD 감지가 우선되어야 한다.

## 부록. 최종 채택 모델 핵심 설정

| 영역           | 설정                                             | 선정 근거                                        |
|--------------|------------------------------------------------|----------------------------------------------|
| Detector     | YOLO11s · v4 · 1 class · imgsz 416 · conf 0.01 | 11,713장 재학습, 헛검출 204개 감소                     |
| Crop         | bbox + 10% padding                             | 검출 상자가 작을 때 객체 절단 방지                         |
| Classifier   | ResNet18 × 10 · 118 classes                    | 기존 ResNet18 9개 + pseudo-label 학습 ResNet18 1개 |
| Input        | 224 및 384                                      | 모양·색과 미세 각인을 함께 포착                           |
| Sampling     | WeightedRandomSampler                          | 클래스 불균형 완화                                   |
| Augmentation | 회전·crop·affine·color jitter·blur·erasing       | 장면 암기 방지, 색상 hue는 작게                         |
| Ensemble     | softmax probability mean                       | 확신 있는 소수의 판단도 반영                             |
| Submission   | det conf × mean class prob                     | 순위 기반 AP score 구성                            |

## 부록 A. 최종 ResNet18 10개 분류기 구성

| Checkpoint                  | 입력·학습 레시피                                     |
|-----------------------------|-----------------------------------------------|
| runs_v3/clf_118.pt          | 224 · v3 데이터                                  |
| runs_v4/clf384s_ep30.pt     | 384 · strong augmentation                     |
| runs_v10/clf_v4.pt          | 224 · v4 데이터                                  |
| runs_v11/clf384s_v4_ep10.pt | 384 · v4 · epoch 10                           |
| runs_v11/clf384s_v4_ep20.pt | 384 · v4 · epoch 20                           |
| runs_v11/clf384s_v4_ep30.pt | 384 · v4 · epoch 30                           |
| runs_v11/clf384s_v4_ep40.pt | 384 · v4 · epoch 40                           |
| runs_v5/clf_bright.pt       | 224 · brightness normalization                |
| runs_v7/clf_clahe.pt        | 224 · CLAHE                                   |
| runs_v20/clf_pseudo.pt      | ResNet18 · 224 · pseudo-label 817개 · 12 epoch |

## 부록 B. 재현 스크립트와 실험 원칙

데이터·학습·진단·제출은 기존 스크립트와 함께 build\_yolo1\_v4, train\_yolo1\_v4, train\_yolo1\_640, pseudo\_make, train\_pseudo, ensemble\_newdet, ood, box\_scale, draw\_pred/check\_pred, aug\_sample로 분리했다. 최종 실행에는 runs/detect/runs\_det\_v4/yolo1\_v4/weights/best.pt를 사용하고, pseudo-label 데이터로 학습한 ResNet18 가중치 runs\_v20/clf\_pseudo.pt를 기존 ResNet18 9개에 추가한다.

재현 원칙은

- ① 평가지표를 먼저 이해하고
- ② 학습·추론 조건을 일치시키며
- ③ 학습 전 데이터 측정을 수행하고
- ④ 한 번에 한 요소만 변경하고
- ⑤ Validation의 신뢰성을 계속 의심하며
- ⑥ 단독 성적이 낮아도 오류가 다른 모델은 보존하고
- ⑦ 모델 상한에 도달하면 누락 데이터부터 찾는 것이다.

자료 기준: 팀 최종 재현 노트북, 공개 실험 노트, 모델별 개인 작업 보고서 및 제출 기록을 통합했다. 서로 다른 실험에서 생성된 내부 Validation 지표는 동일 데이터·동일 평가기가 아닐 수 있으므로 리더보드 점수와 분리해 해석했다.